TECHNICAL PoC REPORT

変圧器の油温を予測し、保全判断につながる条件を確かめる

ETT公開データを用いた油温の同時点推定・6時間先・24時間先予測

4 series | ETTh1 / ETTh2 / ETTm1 / ETTm2

課題提出用 PoC報告



油温予測の検証と、実運用判断に必要な次のデータ

公開ETTでは6時間先の改善を確認したが、故障予測・保全効果は未検証

予測精度の結果と、現場の保全判断へ進むために不足する証拠を分けて示す。

6時間先：4系列すべてで、検証期間で選んだナイーブ基準よりテストMAEが低い

ETTh1 14.7% | ETTh2 26.3% | ETTm1 14.3% | ETTm2 26.7%

予測可能性

6時間先はRidgeが全4系列で選択された。改善幅はテストで14.3〜26.7%。同時点推定もETTh2ではRidgeが基準を改善。

リードタイム

24時間先はETTh1 / ETTm1で改善が1.1〜1.4%。ETTh2 / ETTm2ではPersistenceが最良。長い予測期間の運用価値は確認できない。

判断

今回示せるのは油温の予測可能性まで。実機イベント、警報の誤報負担、保全コストを加えた後ろ向き評価・シャドー運用を次のゲートとする。

推奨：設備・保全ログを含む限定パイロットへ進み、警報用途の採否はイベント評価後に判断する。

今回の問いは「油温を何時間先まで、単純基準より正確に推定できるか」

油温の予測誤差、異常判定、保全価値は別の検証課題として切り分ける。

油温予測を保全判断に使えるか

1 油温を予測できるか — 今回検証
h=0 / 6 / 24時間
ナイーブ基準とのMAE比較

2 予測から異常を判断できるか — データ不足
故障・点検・停止ラベル
警報閾値と運用履歴が必要

3 判断が業務価値につながるか — 未評価
誤警報負担・対応可能時間
点検費と停止損失が必要

4系列に欠損・重複・内部の時刻飛びはなく、頻度別に分けて評価できる

同じETTでも、系列1と系列2では油温の水準が異なるため混ぜて学習しない。

ETTh1

1時間

17,420行　date + 6負荷系列 + OT

2016-07-01 00:00 → 2018-06-26 19:00

ETTh2

1時間

17,420行　date + 6負荷系列 + OT

2016-07-01 00:00 → 2018-06-26 19:00

ETTm1

15分

69,680行　date + 6負荷系列 + OT

2016-07-01 00:00 → 2018-06-26 19:45

ETTm2

15分

69,680行　date + 6負荷系列 + OT

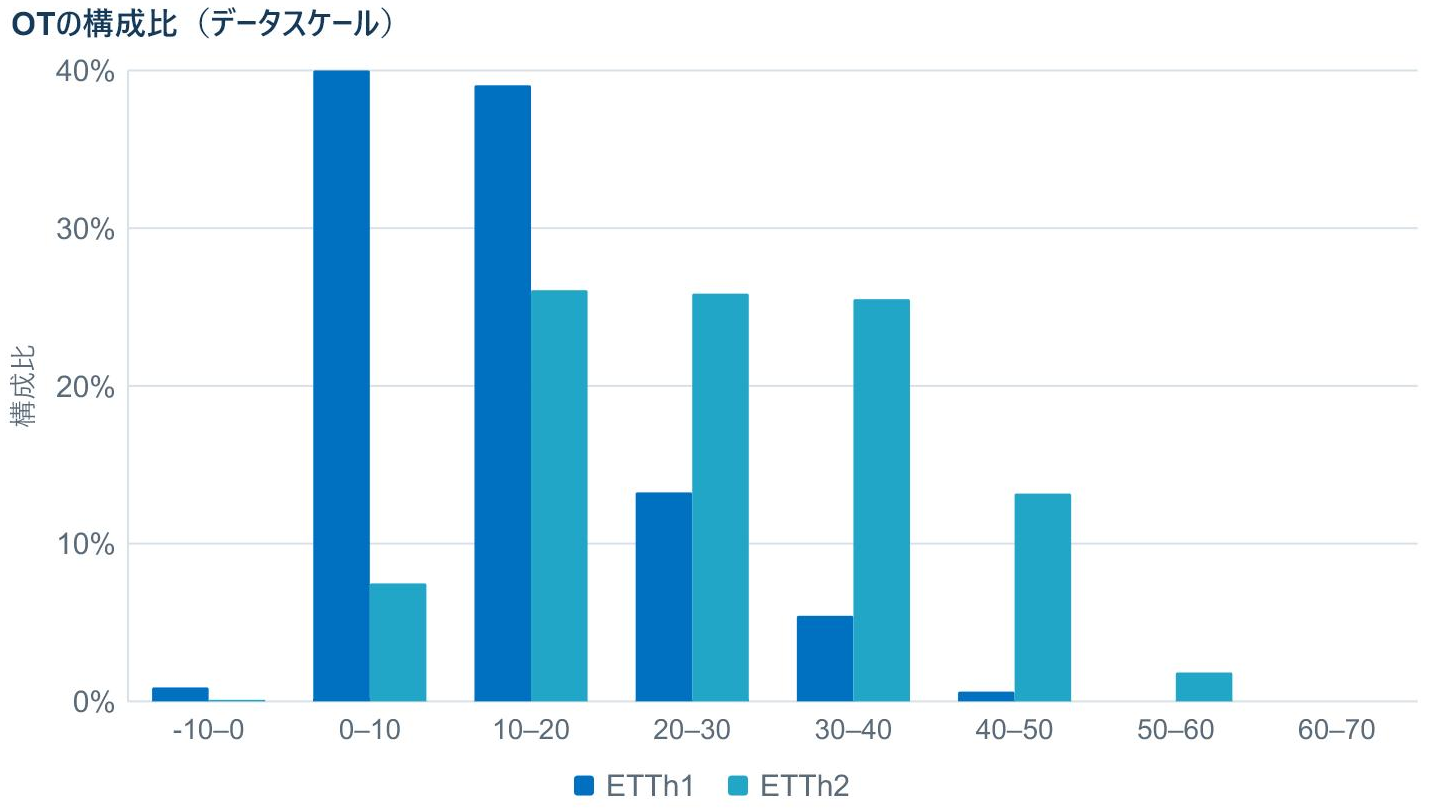
2016-07-01 00:00 → 2018-06-26 19:45

データ範囲の確認

課題配布のETTmは各69,680行。ETDataset README の70,080点という名目値より400点（4日4時間）短いが、各ファイル内に時刻飛びはない。

ETT系列1と系列2で油温分布の水準が大きく異なる

代表的なETTh1 / ETTh2の分布を比べると、油温の母集団を分けた評価が必要になる。



ETTh1

平均 13.3 | 中央値 11.4
95%点 31.5 | 範囲 -4.1～46.0

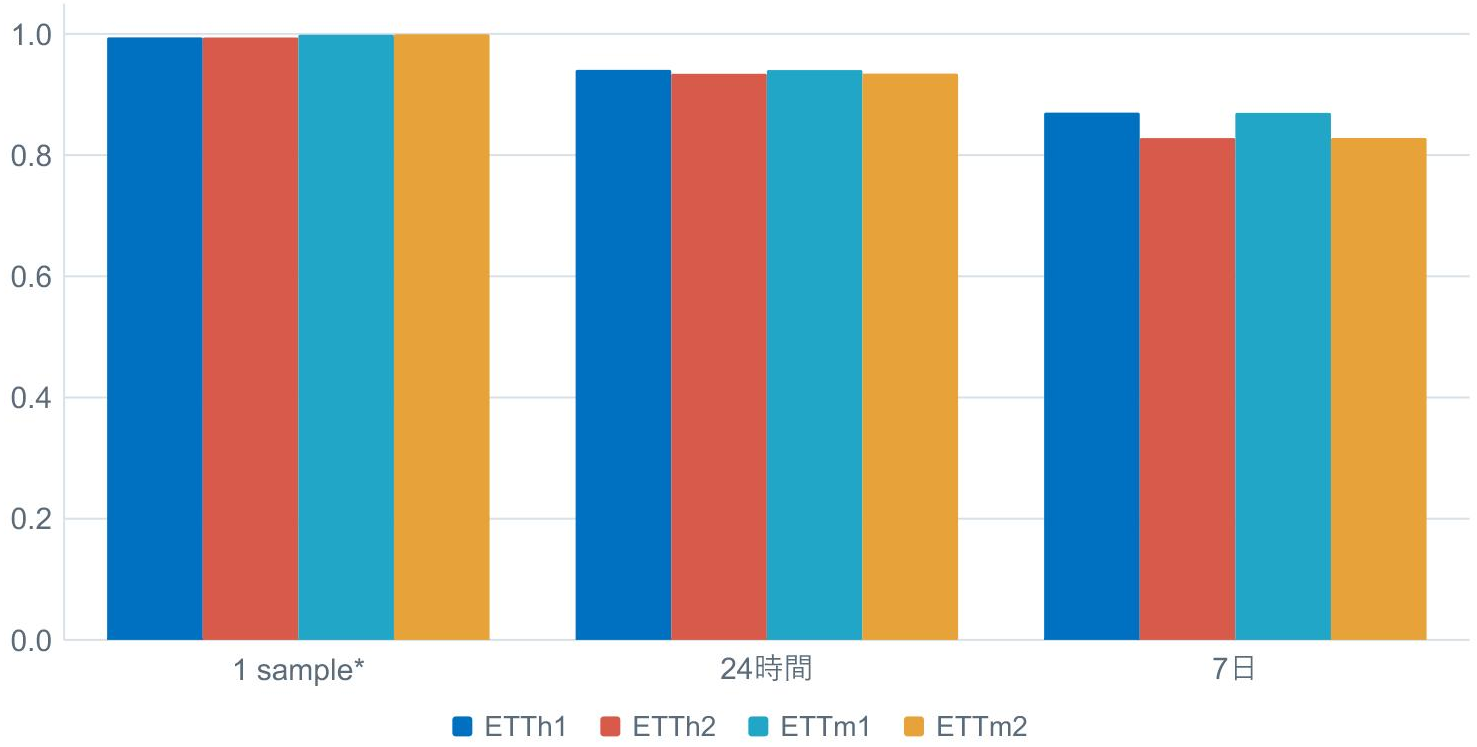
ETTh2

平均 26.6 | 中央値 26.6
95%点 46.1 | 範囲 -2.6～58.9

単位は配布資料に記載なし。負荷列にも物理単位を割り当てず、数値スケールとして解釈する。

油温は直前値への依存が強く、日・週の周期もベースラインに入れる必要がある

自己相関はナイーブ予測に有利な構造を示すため、複雑なモデルだけで評価しない。



直前の油温

1サンプル自己相関
ETTh: 約0.994
ETTm: 約0.999

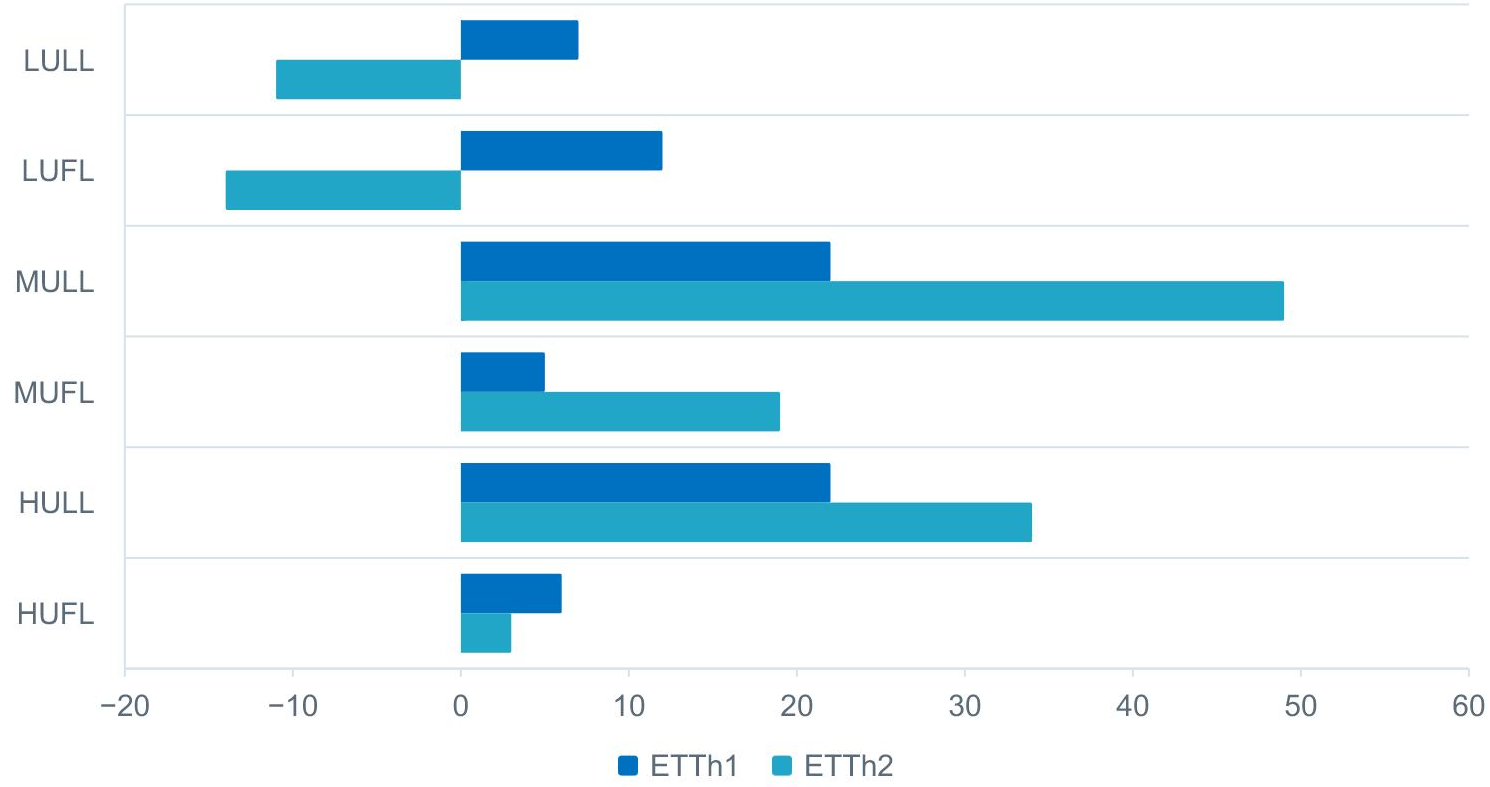
周期性

24時間: 約0.934〜0.941
7日: 約0.828〜0.870

* 1 sample = ETThは1時間、ETTmは15分。

油温と各負荷の線形相関は系列ごとに異なり、単一の相関から原因は決められない

負荷情報は補助特徴として検証し、温度変化の因果関係や故障要因とは解釈しない。



横軸：Pearson r × 100

系列1

最大相関はHULL (r≈0.22) / MULL (r≈0.22)。他の負荷との線形相関は小さい。

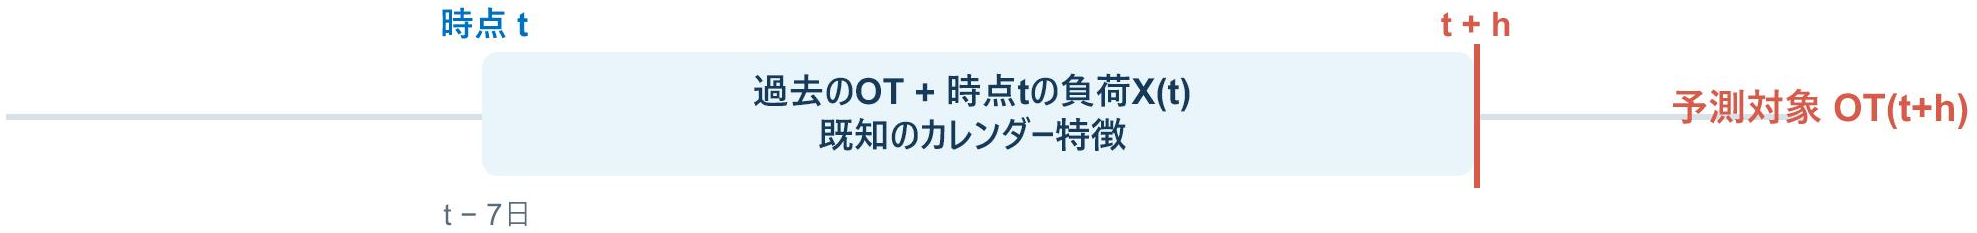
系列2

MULL (r≈0.50) / HULL (r≈0.34) が相対的に大きい。系列間で関係の強さが変わる。

同時点推定と先行予測で「時点tに観測できる情報」を分ける

h=0でOT(t)を入力にしない一方、課題で許可された負荷値X(t)は使う。

観測できる時刻



h = 0 · 同時点推定

入力: X(t)、OT(t−1)・OT(t−2)・OT(t−24h)・OT(t−7d)
除外: OT(t)
用途: 同時刻の推定誤差を確認。早期警告ではない。

h = 6 / 24 · 先行予測

入力: X(t)、観測済みOT(t)とその過去、OT(t+h)の既知カレンダー
未来の負荷値・油温は使用しない。
評価は各tでのローリング予測。

対象時刻で時系列を60/20/20に分け、検証データだけでモデルを選ぶ

ランダム分割を避け、最後の期間を一度だけ最終評価に使う。



比較する基準

Persistence
日周期・週周期の季節ナイーブ

強い自己相関・周期性を超える改善があるか確認。

比較するモデル

Ridge (alpha=10)
HistGradientBoostingRegressor

線形モデルと非線形モデルを固定条件で比較。

選択と最終評価

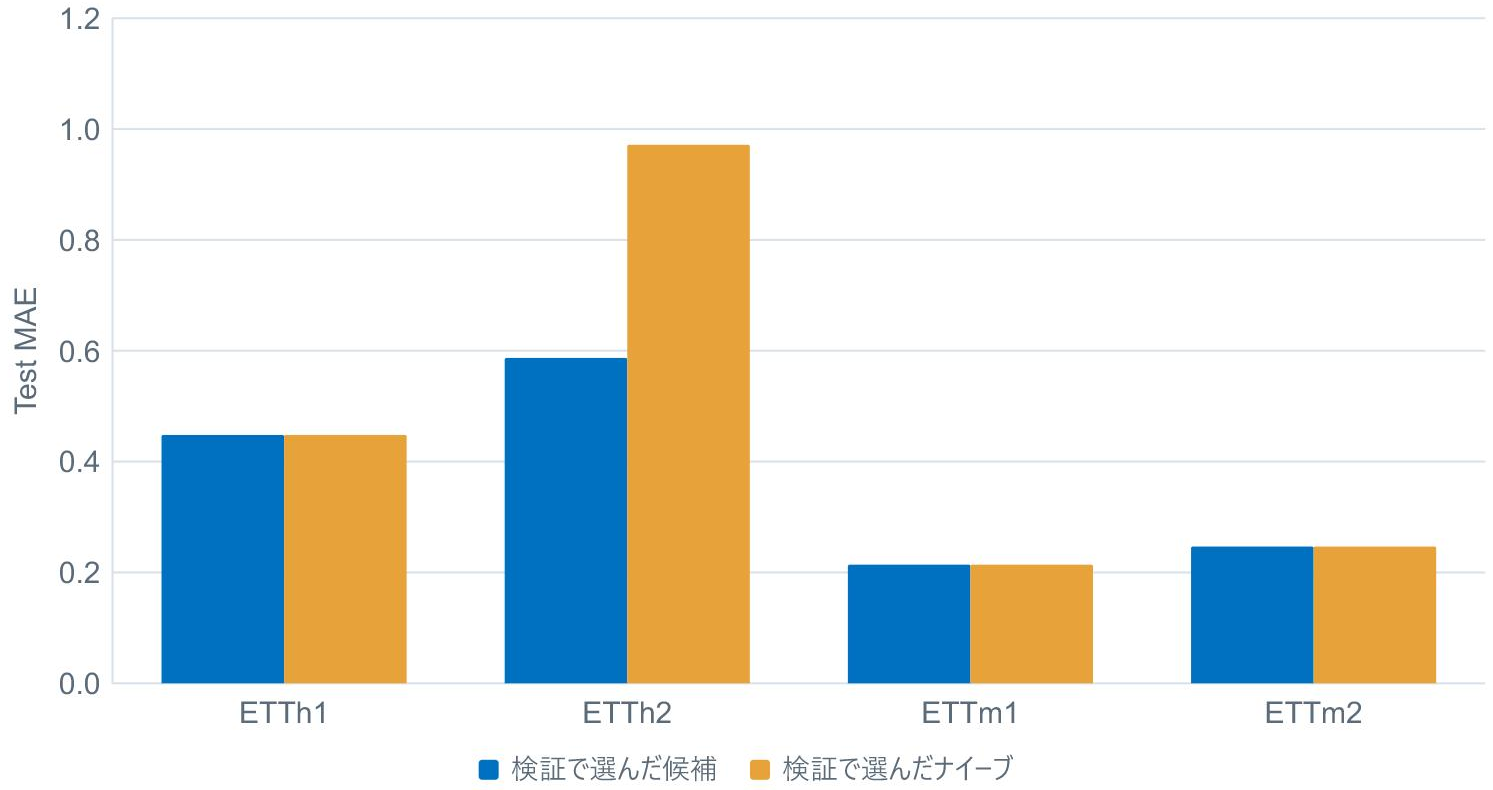
検証MAEが最小の候補を選択。
選択後に学習+検証で再学習し、テストを評価。

MAE / RMSE / R^2を報告。

MAPEはOTに0付近・負値があるため使わない。予測誤差の単位も「配布データのスケール」とする。

同時点推定はETTh2で改善するが、h=0は早期警告の性能ではない

負荷X(t)を使う同時点推定と、直前油温だけのPersistenceを比較する。



ETTh1 / ETTm1

検証でPersistenceが選択。テストMAEは0.448 / 0.214。

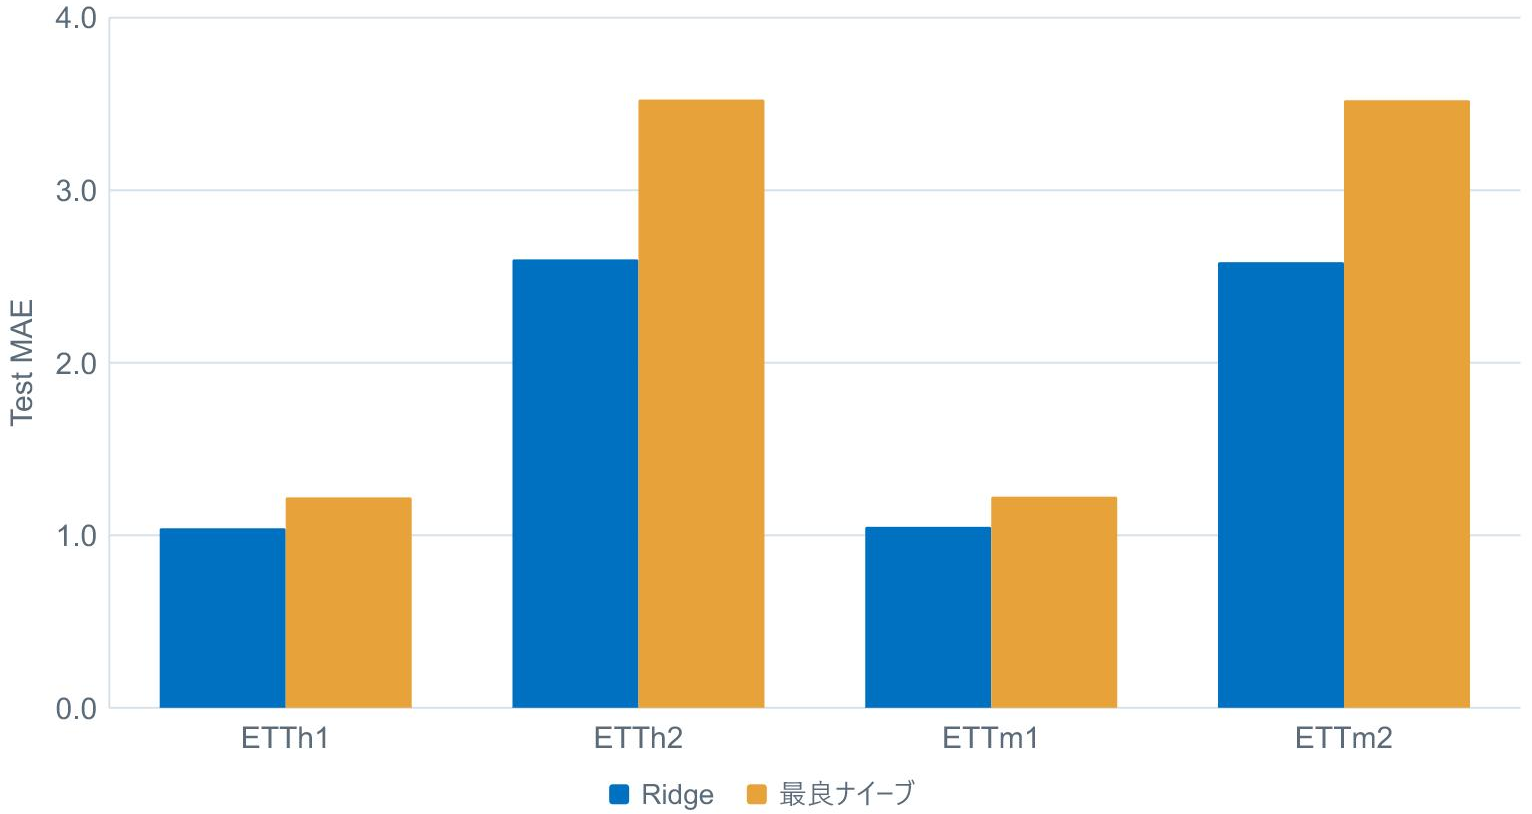
ETTh2

Ridgeが選択。Test MAE 0.587、Persistence 0.972から改善。

この値は「同時刻の負荷から油温を推定する」結果。6時間以上の先行リードタイムとは分けて評価する。

6時間先ではRidgeが4系列すべてでナイーブ基準を上回った

検証で選択したモデルと、検証期間で選んだ最良ナイーブのテストMAEを比べる。



MAE低下幅

ETTh1
14.7%

ETTh2
26.3%

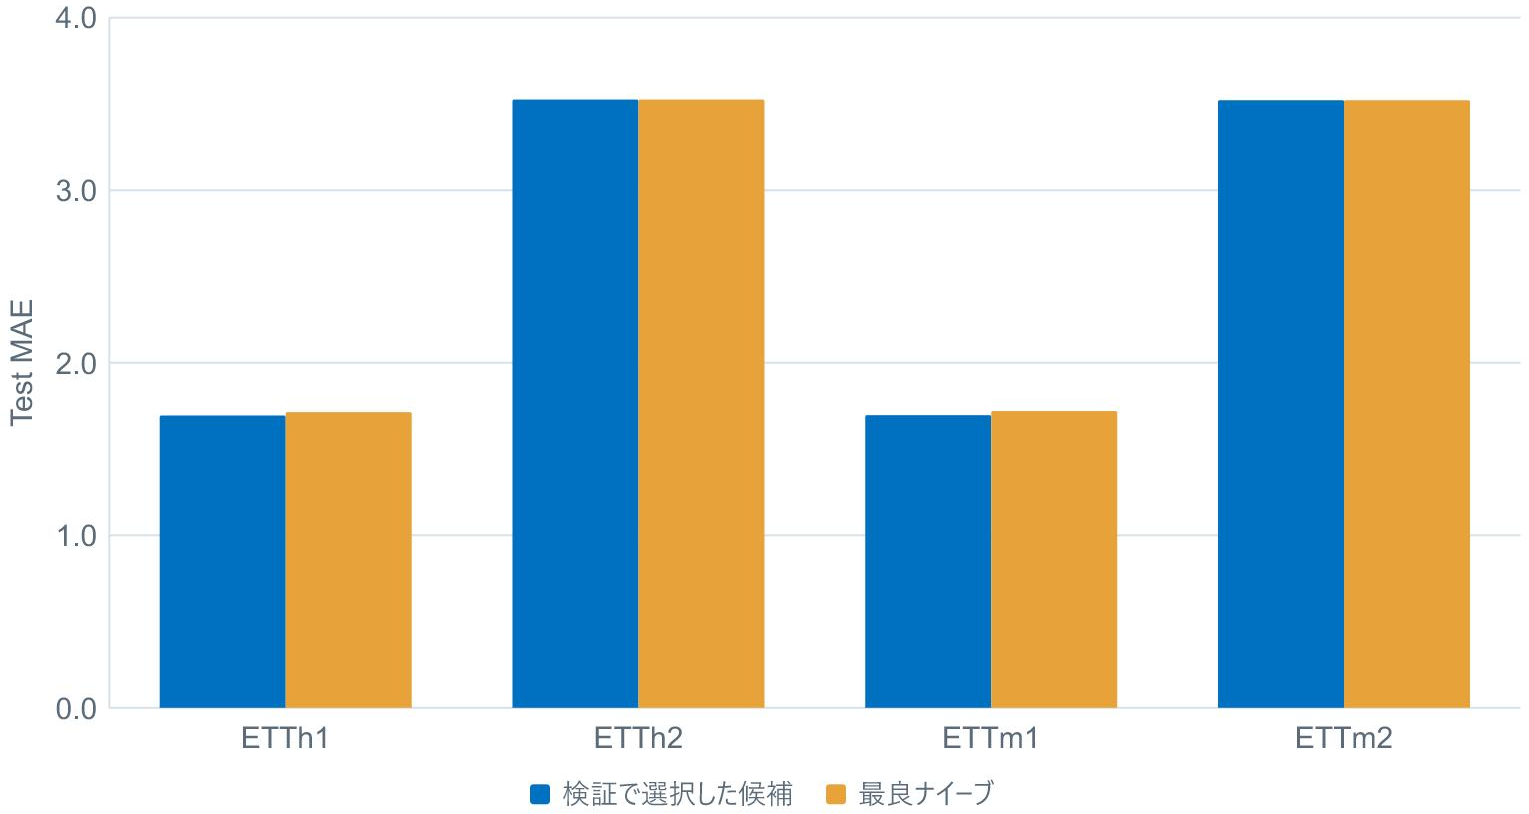
ETTm1
14.3%

ETTm2
26.7%

選択モデル: Ridge(alpha=10)

24時間先では改善が小さく、ETT系列2ではPersistenceが最良だった

同じモデル構成でも、利用可能なリードタイムが長くなると改善幅は縮む。



ETTh1 / ETTm1

RidgeのMAE改善は1.1% / 1.4%。小さい差の安定性は追加の時系列検証が必要。

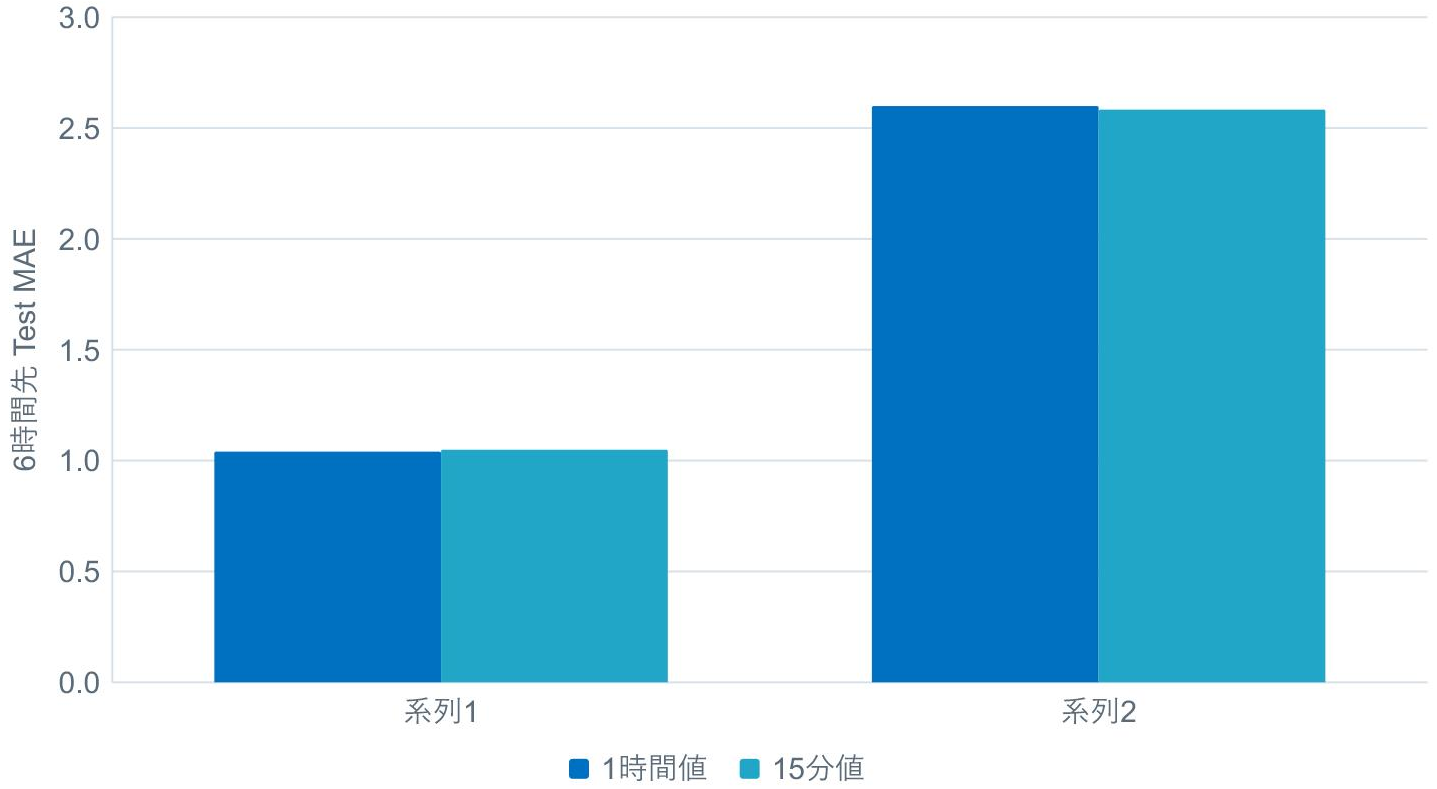
ETTh2 / ETTm2

Persistenceが選択。日周期ナイーブは24時間先では現在OT(t)と同じ値になる。

今回の結果だけでは、24時間先を警報・点検計画へ使う根拠は足りない。

15分値でも1時間値でも、6時間先のMAE水準は同系列で近い

同一期間・同じ変圧器群に由来する系列なので、これは独立な外部再現ではない。



系列1

ETTh1 1.041
ETTm1 1.049

差 0.008

系列2

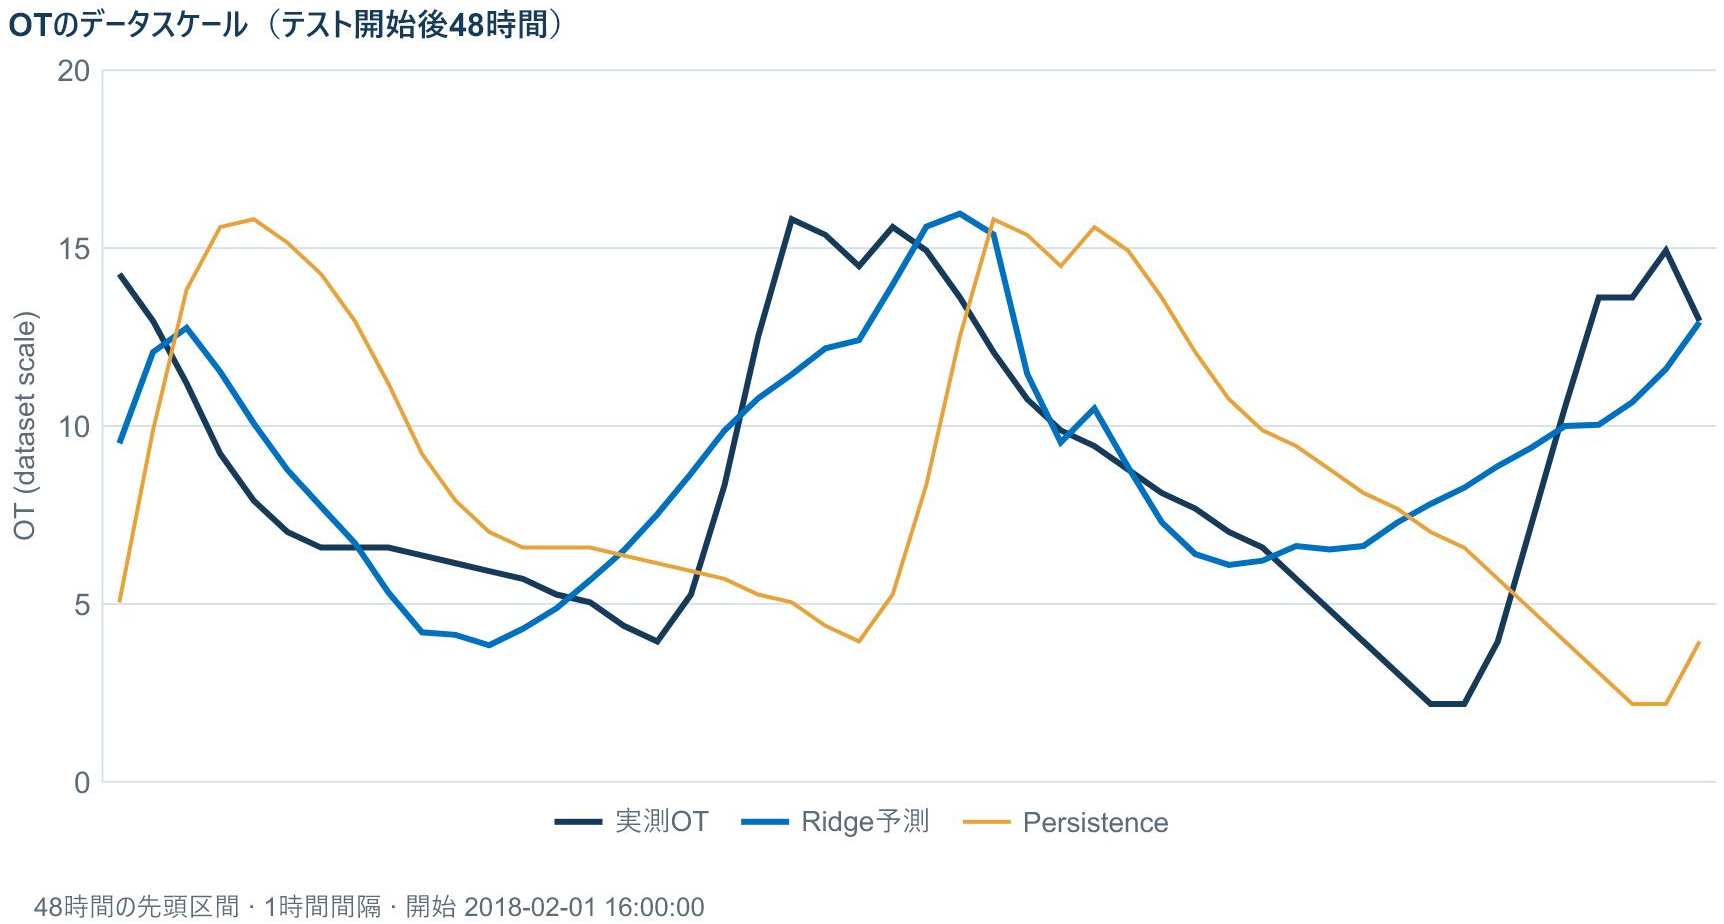
ETTh2 2.599
ETTm2 2.583

差 0.016

頻度違いの確認としては整合的だが、評価期間が重なるため別データへの汎化を証明しない。

代表的なテスト区間で、予測値と実測値のずれを時間軸で確認する

ETTh2の6時間先予測を、同じテスト起点のPersistence基準と重ねる。



読むポイント

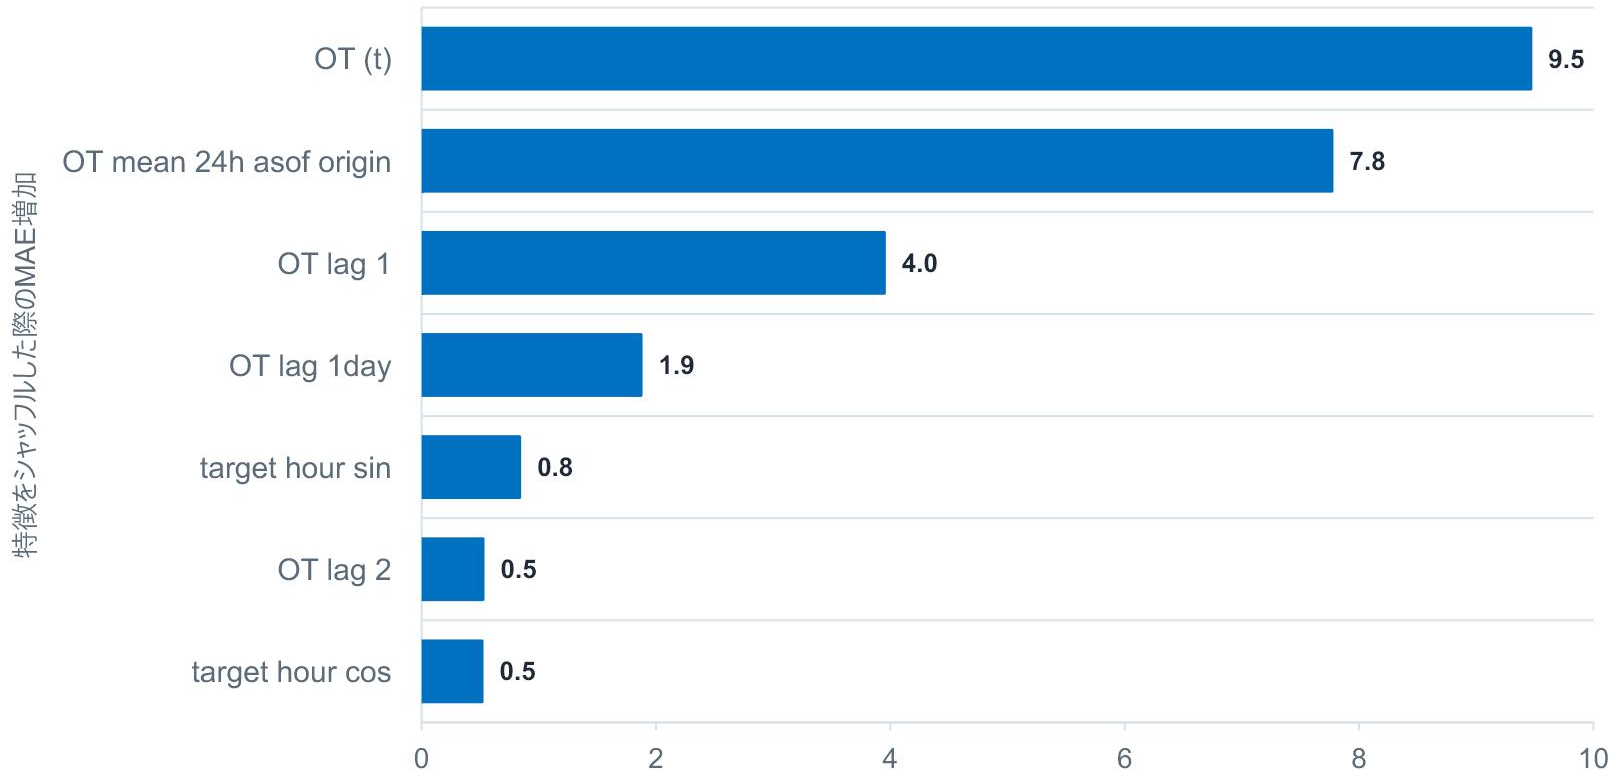
総合MAEだけでなく、急変時の遅れや水準偏りが現場許容内かを確認する。

この図の範囲

ETTh2テストの先頭48時間のみ。故障・警報事例との対応は示していない。

6時間先のRidgeは、現在油温と直近履歴に強く依存する

テストデータ上のPermutation importanceを使い、特徴の寄与を予測誤差増加で確認する。



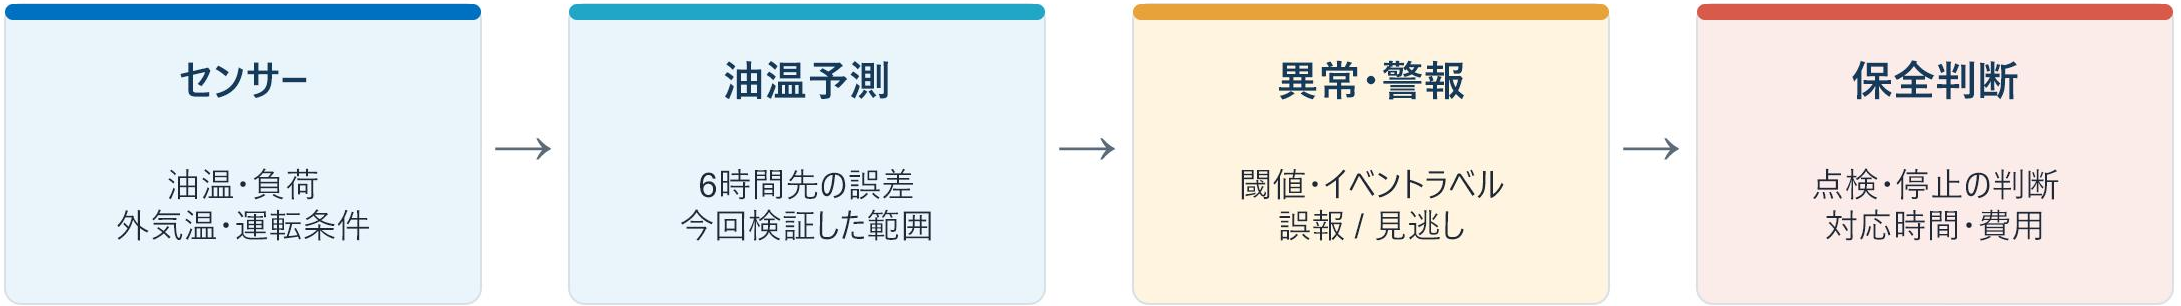
解釈

OT(t)、24時間平均、OT(t−1)が上位。直近の油温状態が6時間先の推定に重要な情報を持つ。

注意：相関する履歴特徴があると重要度が分散する。因果関係や故障要因を示すものではない。

予測誤差だけでは警報の有用性や保全費削減を判断できない

油温の予測値を業務アクションへ結ぶには、故障イベント・閾値・コストが必要になる。



今回の配布ETTにない情報

故障・異常・点検ラベル　現行閾値・警報履歴　外気温・設備属性　点検 / 停止コスト

したがって、ROI・誤報率・故障検知率は算出していない。

次は実設備ログで後ろ向き評価を行い、警報の負担と保全価値を判断する

予測モデルを即時運用に載せず、データ準備・イベント評価・シャドー運転をゲートで進める。

01 定義・整備

設備ID・単位・周期
時刻同期・欠損
保全判断の業務要件

→

02 後ろ向き評価

故障・点検ラベル
実運用ナイーブと比較
閾値別の誤報 / 見逃し

→

03 シャドー運転

実測を用いた定期予測
現場アクションは変更せず
アラーム負担を計測

→

04 導入ゲート

必要な警告時間
許容誤報数 / 月
対応責任者・価値確認

合意する成功条件

必要な警告リードタイムでの再現性 · 見逃し率と誤報の上限 · 現場が処理できるアラーム量 · 保全コストと運用責任

期間・閾値は対象設備、履歴の粒度、保全担当者へのヒアリング後に設定する。

固定条件と出力を残し、結果の再計算とレビューができるようにした

分析コードは4系列の品質確認・EDA・比較モデル・評価指標を一度に出力する。

特徴量と予測起点

負荷6系列は起点tの観測値。OTはh=0では過去値のみ、h=6/24ではOT(t)までを使用。カレンダー特徴は予測時刻から生成。

比較したモデル

Persistence / 日周期・週周期ナイーブ / Ridge(alpha=10) / HistGradientBoostingRegressor(180 iterations, 15 leaves, min leaf 40)。固定パラメータ。

評価・解釈

検証MAEで候補を選択。最終モデルは学習+検証で再学習しテストを評価。特徴量のPermutation importanceはテストで説明用に算出。

再現コマンド

```
python -m pip install -r requirements.txt
python src/run_analysis.py --data-dir data --output-dir results
```

品質・EDA・評価結果と実行条件をCSV・JSONで保存。

データ、予測課題、モデル仕様の参照元

データ出典を明示し、配布資料にない単位・イベント・ROIは推定しない。

1	**ETT Dataset**	Zhou et al. · ETT-small data and feature overview https://github.com/zhouhaoyi/ETDataset
2	**Informer paper**	Zhou et al. (2021), AAAI · ETT benchmark reference https://arxiv.org/abs/2012.07436
3	**Ridge regression**	scikit-learn 1.6 API reference https://scikit-learn.org/1.6/modules/generated/sklearn.linear_model.Ridge.html
4	**Histogram gradient boosting**	scikit-learn 1.6 API reference https://scikit-learn.org/1.6/modules/generated/sklearn.ensemble.HistGradientBoostingRegressor.html
5	**Permutation importance**	scikit-learn 1.6 User Guide https://scikit-learn.org/1.6/modules/permutation_importance.html